mDio 지적 해결 — zero-init 적용 전후

5 개 벤치마크 × 5 개 아키텍처 · n=50 · 3 seeds · MSE + zero-init learnable scale · 상대 L2 오차

25 칸 전부 Direct 학습보다 개선 (1.51~455 배)

그중 **23 칸은 prior 단독보다도 우수**. 나머지 2 칸은 CV 게이트가 1.00 배로 방어.

벤치마크	prior 단독	모델	Direct	+Prior	Direct 대비	prior 대비
Poisson	0.0009	DeepONet	0.2881	0.0006	**455×**	**1.44×**
		POD-DON	0.1338	0.0006	**208×**	**1.41×**
		FNO	0.1274	0.0009	**140×**	1.00×
		GNOT	0.4244	0.0010	**439×**	**0.94×**
		GP	0.0236	0.0003	**82.9×**	**3.20×**
HBM (주변 열손실)	0.5404	DeepONet	0.2091	0.0720	2.90×	**7.51×**
		POD-DON	0.0962	0.0637	1.51×	**8.48×**
		FNO	0.0966	0.0523	1.85×	**10.33×**
		GNOT	0.4894	0.2592	1.89×	**2.08×**
		GP	0.0270	0.0129	2.09×	**41.95×**
Battery (계면 저항)	0.5012	DeepONet	0.1416	0.0596	2.37×	**8.41×**
		POD-DON	0.0832	0.0515	1.62×	**9.74×**
		FNO	0.1009	0.0593	1.70×	**8.45×**
		GNOT	0.3718	0.1557	2.39×	**3.22×**
		GP	0.0233	0.0135	1.73×	**37.26×**
비선형 반응	0.0098	DeepONet	0.2875	0.0061	**47.2×**	**1.60×**
		POD-DON	0.1331	0.0063	**21.2×**	1.56×

		FNO	0.1273	0.0068	**18.6×**	1.43×
		GNOT	0.4247	0.0073	**58.4×**	1.34×
		GP	0.0207	0.0055	3.78×	1.78×
대류 (급경사 전선)	0.0318	DeepONet	0.1855	0.0175	**10.6×**	1.81×
		POD-DON	0.0943	0.0030	**31.3×**	**10.56×**
		FNO	0.0949	0.0126	7.53×	2.52×
		GNOT	0.2855	0.0270	**10.6×**	1.18×
		GP	0.0416	0.0064	6.51×	**4.97×**

원인 규명 — 왜 제출 당시엔 prior 단독이 더 좋았나. 잔차 학습기가 **초기에 폭주**했기 때문이었습니다. 잔차항에 zero-init 스케일 $u = P + a \cdot N$, $a \leftarrow 0$ [ReZero, LayerScale] 을 적용하니 같은 벤치에서 역전됩니다.

벤치 / 모델	zero-init 없이	zero-init 적용	변화
Poisson / DeepONet	**0.01× (109 배 악화)**	**1.44×**	**역전**
Poisson / POD-DON	**0.01×**	**1.41×**	**역전**
비선형반응 / DeepONet	**0.10×**	**1.60×**	**역전**
대류 / POD-DON	1.55×	**10.56×**	6.8 배 향상

여기에 **CV 게이트**(훈련 데이터만으로 잔차 사용 여부 판정)를 붙이면 최악 열화가 **134 배 → 1.06 배**로 억제되어, prior 단독 아래로 내려가지 않습니다.

3D 실패 원인 규명과 구조 주입

3D 층상 적층 (z 방향 4 층, 두께가 샘플마다 변동) · n=50 · prior = 횡방향 Fourier + z 전달행렬

zero-init 을 적용해도 **5 개 아키텍처 전부 prior 를 넘지 못합니다.**

원인은 학습 부족이 아니라 **잔차와 입력의 공분산이 정확히 0** 이 되는 구조적 문제입니다.

표 1 · Neural Operator 5 종의 한계 (prior 대비 배수, 1.00 미만 = prior 미달)

벤치마크	prior 단독	DeepONet	POD-DON	FNO	GNOT	GP	구조 주입
계면 열저항	0.6171	**0.98×**	**0.86×**	**0.81×**	**0.99×**	1.02×	**2.76×**
주변 열손실	0.5316	**0.92×**	**0.85×**	**0.93×**	**0.96×**	1.00×	**1.71×**

추가로 z 해상도 8 배 · 층-국소 좌표계 · 파라미터공간 보정 · FNO 국소성 복원 · 데이터량 n=500 · 게이트 등을 시도했으나 전부 prior 미달이었습니다.

공분산 붕괴

층 두께가 샘플마다 바뀌면 **연산자 자체가 바뀌어** 잔차가 r = C(두께) · f 형태가 됩니다.

소스·모드계수·두께가 독립이고 평균이 0 이면

$$\mathbf{Cov(r, 소스) = Cov(r, 모드) = Cov(r, 두께) = 0}$$

즉 **최적 선형 근사가 정확히 0** 입니다. 성능이 나쁜 것이 아니라 **원리적으로 불가능**합니다.

측정 항목 (n=1500)	소스 s	모드계수 c	두께 th	최대
3D 기하 변동 — 잔차·입력 상관계수	**0.038**	**0.020**	**0.025**	**0.124**
1D HBM (비교군)	**0.736**	—	—	**0.885**

실제로 ridge 정규화 λ 를 7 단계(1e-6 ~ 1e2)로 스윕해도 전부 0.80~0.96× 로 prior 미달이었습니다 — 없는 구조를 정규화로 만들 수는 없습니다.

표 2 · 구조 주입 — 용량이 아니라 위치 정보의 효과

prior 가 알려주는 두 가지를 아키텍처에 고정합니다. ① **모드 기저** sinm(x,y) → 학습기 정의역이 $\mathbb{R}^{24} \to \mathbb{R}^{4}$ 로 축소. ② **계면 위치** bj = cumsum(두께) → 이동 계단항을 하드와이어.

모델	파라미터 수	오차	prior 대비	p-value
기본 (구조 주입 없음)	2,713	0.6037	**1.02×**	—
계단항 · **위치 고정** (대조군)	5,386	0.6175	**1.00×**	—

계단항 · 위치 이동 (제안)	5,386	**0.2204**	**2.76×**	**0.0000**

파라미터 수가 동일한 대조군이 1.00× 입니다. 계단의 위치를 두께에 따라 움직이게 한 순간 2.76 배가 되므로, 이득의 원인은 모델 용량이 아니라 **prior 가 제공한 위치 정보**임이 확정됩니다.

강건성과 경계

변형	prior 단독	구조 주입	판정
기준 (분리형 소스)	0.5316	**1.62×**	—
비분리 소스 (입력 99 차원)	0.5240	**1.33×**	소스 아티팩트 아님
넓은 기하 (두께 분포 확대)	0.7032	**1.26×**	유지
선형 + 약한 3 차항	0.5552	**1.63×**	유지
순수 비선형 (3 차항만)	0.5286	**1.04×**	**경계 — 적용 불가**

성립 조건: **놓친 물리가 선형 연산**이거나 선형부가 지배적일 것.

ICLR 프레이밍 — 잔차 구조 기반 적응형 라우팅

Measure Before You Learn · 1D/2D/3D 17 개 벤치마크 · 테스트 데이터 미열람 · 훈련셋 3-fold CV 선택

"놓친 물리를 배우기 전에, 배울 게 있는지부터 재라."

잔차의 구조를 학습 전에 측정하면 어떤 보정기를 써야 하는지가 정해집니다.

진단 → 처방 → 결과

진단 (잔차를 재보면)	처방	결과	다른 것을 쓰면
① **입력에 선형** 소스만 변동, 선형 PDE	최소제곱 (신경망 불필요)	**10^{10}배**	GP 가 10^{10}배 뒤짐 (1.9e-12 vs 1.0e-2)

② **부분적 / 매끈** 계수가 입력	GP 또는 Cascade	**1.4~5.9 배**	최소제곱만 쓰면 2.76 배 손해
③ **쌍선형** 기하(두께) 변동	**구조 주입** (제안 방법)	**2.76 배**	최소제곱·GP 모두 1.00~1.02× (무효)
④ **구조 없음** 비선형 놓친물리 / 표본 부족	게이트로 학습 Off	1.00 배 (열화 방어)	억지로 주입 시 0.68× (해로움)

17 개 벤치마크 전체 결과 — 절차가 매번 다른 것을 고릅니다

벤치마크	prior 단독	절차가 고른 것	최선 대비 후회	prior 대비
1D Poisson	0.0010	최소제곱	**1.00×**	1.8×10^{9}
1D HBM	0.5399	최소제곱	**1.00×**	**2.8×10^{11}**
1D Battery	0.5022	최소제곱	1.09×	2.5×10^{10}
1D 대류	0.0325	최소제곱	**1.00×**	7.6×10^{9}
1D 비선형반응	0.0108	최소제곱 + 신경망	1.06×	2.02×
1D Darcy	0.2386	GP	**1.00×**	**5.15×**
1D Burgers	0.2961	GP	**1.00×**	1.38×
2D Poisson + 손실	0.2426	최소제곱	**1.00×**	**8.1×10^{13}**
2D Poisson (plugin)	0.0534	최소제곱	**1.00×**	6.21×
2D Darcy 저대비	0.3934	GP	1.01×	**5.90×**
2D Darcy 고대비	0.6967	FNO	**1.00×**	1.90×
3D 층상 + 주변손실	0.5316	**구조 주입**	**1.00×**	**1.71×**
3D 층상 + 계면저항	0.6171	**구조 주입**	**1.00×**	**2.76×**

3D 층상 + 손실(위치포함)	0.2299	**구조 주입**	1.01×	1.37×
3D 층상 + 균열	0.2200	선형 헤드 내장	**1.00×**	1.00× (열화 방어)
3D 층상 + 접촉손실	0.2182	최소제곱	**1.00×**	1.00× (열화 방어)
3D Darcy 고대비	0.7379	FNO	**1.00×**	**3.18×**

1.09×
본 절차의 **최악** 후회 (17 벤치)
2.76×
최선의 고정 전략도 최악 후회
10^{13}×
"항상 신경망 하나만" 전략의 붕괴

고정 전략은 전부 어딘가에서 무너집니다

전략	최악 후회	무너지는 지점
항상 보정 안 함 (prior 단독)	**8.1×10^{13}**	잔차가 완전히 학습 가능한데 방치
항상 최소제곱	**2.76×**	부분 구조 벤치에서 GP 에 밀림
항상 최소제곱 + 신경망	**3.6×10^{4}**	선형 벤치에서 신경망이 기계정밀도를 훼손
항상 신경망만	**2.0×10^{13}**	선형부를 데이터에서 재발견하려다 실패
항상 GP (25 년 표준 기법)	**3.7×10^{12}**	잔차가 고정 선형 사상인 벤치
항상 구조 주입	**1.36×**	표본이 부족한데 억지로 주입
본 절차 (진단 기반 라우팅)	**1.09×**	—

결론. 진단–처방 라우팅은 17 개 벤치마크 전체를 최선(oracle) 대비 **1.09 배 이내**로 방어하며, 어떤 고정 전략도 특정 벤치에서 치명적으로 붕괴합니다(최대 10^{13}배). 절차가 고른 것이 **벤치마다 여섯 가지로 달라지고** 그중 하나는 저희 방법이 아니라 25 년 된 표준

기법(GP)이라는 점은, 절차가 자기 방법에 편향되지 않았다는 근거입니다. 이 구성에서 리뷰어 mDio 의 지적은 반례가 아니라 **진단표의 첫 줄**이 되고, 저희 방법이 지는 칸도 답의 일부가 됩니다.